

Universidade do Minho

Mestrado em Engenharia e Gestão de Sistemas de Informação

Relatório Final

Tema 2 — Escalabilidade Horizontal e Custo Marginal
em Microserviços

Membros do Grupo: PG61463 – Eduardo Dias
PG47542 – Nuno Martinho
PG58760 – Clementina Kulivala
PG58761 – Golda Kangunga

Unidade Curricular: Arquiteturas de Sistemas de Informação Distribuídos (ASID)

Ano letivo: 2025/2026 — 2.º Semestre

Sistema em estudo: Online Boutique (Google Microservices Demo)

Data: Maio de 2026

Escalabilidade Horizontal e Custo Marginal em Microserviços: Um Estudo Experimental com o Google Online Boutique

EDUARDO DIAS, Universidade do Minho, Portugal

NUNO MARTINHO, Universidade do Minho, Portugal

CLEMENTINA KULIVALA, Universidade do Minho, Portugal

GOLDA KANGUNGA, Universidade do Minho, Portugal

Este artigo estuda o impacto da escalabilidade horizontal sobre o desempenho e o custo marginal de uma aplicação de microserviços, utilizando o Google Online Boutique como sistema em estudo. Três cenários experimentais foram desenhados para isolar progressivamente o efeito do escalamento: C1 (configuração baseline, 1 réplica por serviço), C2 (escalamento seletivo do candidato a *bottleneck* primário) e C3 (escalamento uniforme de todos os serviços *stateless*). Foram executados testes comparativos (15–25 utilizadores, *think times* realistas) e testes exaustivos (25–150 utilizadores, *think times* agressivos) com o Locust. Os resultados revelam dois efeitos contra-intuitivos: (1) o cenário C2 atingiu saturação a 50 utilizadores, antes do C1 a 75 utilizadores, evidenciando que o escalamento seletivo mal direcionado pode degradar o sistema por via da *connection affinity* do gRPC/HTTP2; (2) o cenário C3, apesar de consumir 3× mais recursos, deslocou o ponto de saturação para ~150 utilizadores, confirmando que o escalamento uniforme de serviços *stateless* é eficaz mas com custo marginal crescente. Os resultados suportam a hipótese de que o *connection affinity* do gRPC/HTTP2 limita estruturalmente a eficácia do escalamento horizontal sem balanceamento ao nível de pedido.

Additional Key Words and Phrases: microserviços, escalabilidade horizontal, custo marginal, gRPC, *connection affinity*, Kubernetes, testes de carga

1 Introdução

A escalabilidade horizontal — adicionar réplicas de serviços em vez de aumentar os recursos de uma instância — é uma das promessas centrais das arquiteturas de microserviços. Em teoria, duplicar o número de réplicas de um serviço deveria duplicar a sua capacidade. Na prática, múltiplos fatores arquiteturais limitam este ganho: dependências de componentes *stateful* partilhados, balanceamento de carga ao nível de conexão em vez de pedido, e rendimentos marginais decrescentes quando o *bottleneck* se desloca para outro serviço após o escalamento.

Este trabalho analisa de que forma diferentes estratégias de escalabilidade horizontal afetam o desempenho e o custo marginal do *Online Boutique* [1], uma aplicação de comércio eletrónico de código aberto com 11 microserviços disponibilizada pela Google como referência de boas práticas. A escolha justifica-se por reunir características relevantes para o tema: comunicação via gRPC [2], serviços *stateless* e *stateful*, dependências em cascata e suporte nativo a observabilidade via OpenTelemetry [3] e Jaeger [4].

As questões de investigação que orientam o estudo são:

- **RQ1:** Que serviços dominam a degradação de desempenho nos *workflows* principais à medida que a carga aumenta?
- **RQ2:** Escalar seletivamente o serviço mais pressionado melhora de forma mensurável *throughput*, latência e taxa de falhas?
- **RQ3:** O ganho por réplica adicional justifica o custo, ou surgem rapidamente rendimentos marginais decrescentes?

- **RQ4:** Até que ponto a eficácia da escalabilidade horizontal é condicionada pela natureza *stateless* vs. dependência de componentes *stateful* partilhados?

1.1 Enquadramento Teórico

Microserviços e escalabilidade horizontal. As arquiteturas de microserviços estruturam uma aplicação como um conjunto de serviços independentemente implantáveis que comunicam por protocolos leves [11, 12]. A principal promessa arquitetural é a capacidade de escalar, implantar e evoluir cada serviço de forma autónoma. O **escalamento horizontal** (*scale-out*) — adicionar réplicas em vez de aumentar recursos de uma instância — é a estratégia preferida porque não tem teto físico e aumenta a disponibilidade. Porém, a Lei de Amdahl [10] quantifica um limite fundamental: se uma fração s do trabalho é serial, o speedup máximo é $1/s$, independentemente do número de réplicas. Neste estudo, derivou-se empiricamente $s \approx 0,654$ (Secção 7.3), imposta pelo protocolo de comunicação — não apenas pelo código.

gRPC, HTTP/2 e connection affinity. O gRPC [2] usa HTTP/2 como transporte, com conexões persistentes e multiplexadas. Ao contrário do HTTP/1.1, onde cada pedido pode ser roteado independentemente, os pedidos gRPC partilham conexões de longa duração — o balanceamento de carga ao nível TCP (L4) distribui conexões, não pedidos. Uma vez estabelecida uma conexão a uma réplica, todos os pedidos nessa conexão permanecem nela [8, 9]. Este fenómeno, documentado na literatura técnica sobre gRPC em Kubernetes, é o mecanismo central que explica os resultados dos cenários C2 e C4 deste estudo.

Kubernetes e balanceamento de carga. O Kubernetes opera ao nível L4 através do kube-proxy (iptables/IPVS), adequado para HTTP/1.1 mas insuficiente para gRPC. A resolução requer balanceamento ao nível L7 (pedido), tipicamente fornecido por um *service mesh* (Istio, Linkerd) ou por balanceamento do lado do cliente. O *Horizontal Pod Autoscaler* (HPA) [6] oferece escalamento reativo, mas pressupõe que o escalamento é eficaz — pressuposto questionado pelos resultados deste estudo.

Componentes stateful e limite de escalabilidade. A distinção entre serviços *stateless* e backends *stateful* é central na análise de escalabilidade. Serviços *stateless* podem ser replicados sem coordenação; backends *stateful* (bases de dados, caches) concentram estado e contenção, e a sua escalabilidade requer estratégias distintas (*sharding*, replicação com consistência eventual). O *redis-cart* deste sistema é *single-threaded* e não beneficia de escalamento horizontal simples, ao contrário dos 11 serviços aplicacionais.

Observabilidade. A identificação de bottlenecks em sistemas distribuídos requer os três pilares de observabilidade: métricas agregadas (`kubectl top`), *traces* distribuídos (Jaeger/OpenTelemetry) e *logs*. Neste estudo, os *traces* Jaeger confirmaram o fan-out $\times 6$ de W1 e a sequencialidade total de W3; sem observabilidade, a seleção do candidato a bottleneck teria de assentar em suposições arquiteturais — exatamente o que levou o C4 a falhar.

Comparação com sistemas de produção. A Netflix resolveu o mesmo problema de *connection affinity* com balanceamento do lado do cliente (Ribbon/Envoy). A Twitter/X enfrentou os mesmos limites de componentes *stateful* (Redis) ao migrar para microserviços, recorrendo a *sharding* e separação de leituras/escritas. A Amazon opera com escalamento por serviço independente, mas enfatiza que o escalamento de um serviço aumenta a carga nos seus dependentes — exatamente o efeito cascata observado no C4 deste estudo.

2 Arquitetura do Sistema

O *Online Boutique* é composto por 11 microserviços e um componente *stateful* (Redis). A arquitetura segue o padrão *Database-per-Service* — apenas o *redis-cart* mantém estado persistente. Todos

os serviços aplicativos são *stateless*. A comunicação interna é exclusivamente via gRPC sobre HTTP/2; o único ponto de entrada externo é o frontend, que expõe HTTP/1.1.

Nota conceptual importante: o *cartservice* é um serviço aplicativo *stateless* que depende de um *backend stateful* partilhado (*redis-cart*). Escalar réplicas do *cartservice* não escala o recurso que concentra o estado e a contenção. Esta distinção é central para a interpretação dos resultados.

2.1 Workflows Analisados

Foram seleccionados três *workflows* que cobrem padrões distintos de escalabilidade.

W1 — Browse Product (GET /product/{id}): desencadeia 6 chamadas gRPC paralelas ao *productcatalogservice* por pedido — confirmado com traces Jaeger. É a operação mais frequente (peso 10 no Locust) e o principal *driver* de carga do *productcatalogservice*.

W2 — Add to Cart (POST /cart): envolve validação do produto e persistência no *redis-cart* via HSET bloqueante. É pré-requisito funcional do *checkout*: falha aqui bloqueia W3 em 100% dos casos.

W3 — Checkout (POST /cart/checkout): o *checkoutservice* orquestra 6 serviços em sequência — a latência total é a soma das latências individuais, sem paralelismo. A operação *EmptyCart* ocorre no final, após *checkout* bem-sucedido (confirmado no Jaeger).

2.2 Tabela Chamada → Dependências → Risco

Tabela 1. Análise de risco por chamada nos três workflows. Risco: ALTO = caminho crítico com fan-out, dependência *stateful* ou bloqueio em cascata.

WF	Chamada	Origem	Destino	Fan-out	Risco
W1	GET /product	Locust	frontend	—	ALTO
W1	GetProduct (×6)	frontend	productcatalog	6 paralelas	ALTO
W1	GetCurrencies	frontend	currencyservice	1	MÉDIO
W1	ListRec.	frontend	recommend.	1 (chama catalog)	BAIXO
W2	POST /cart	Locust	frontend	2 sequenciais	ALTO
W2	GetProduct	frontend	productcatalog	1	MÉDIO
W2	AddItem (HSET)	frontend	cart→redis	1 bloqueante	ALTO
W3	POST /checkout	Locust	frontend→checkout	6 sequenciais	ALTO
W3	GetCart	checkoutservice	cart→redis	1	ALTO
W3	Charge	checkoutservice	paymentservice	1	ALTO
W3	SendEmail	checkoutservice	emailservice	1	BAIXO
W3	EmptyCart	checkoutservice	redis-cart	1	MÉDIO

2.3 Serviços-Alvo

Com base na análise de fan-out, tipo de estado e presença nos três *workflows*, foram seleccionados três serviços-alvo para orientar os cenários experimentais.

Tabela 2. Serviços-alvo selecionados (ST1–ST3), tipo, cenário de escala e justificação.

Serviço-alvo	Tipo	Cenário	Justificação
ST1 productcatalog- service	— Stateless	C2 (×3 réplicas)	Candidato a bottleneck primário: fan-out ×6 em W1, sem cache, chamado em W1/W2/W3 por 3 serviços. Stateless — escalamento seguro. Testa RQ1 e RQ2.
ST2 redis-cart	— Stateful (backend)	C1/C2 (observação)	Único componente stateful partilhado; single-threaded. Escalar o cartservice não resolve a pressão no redis-cart. Testa RQ4.
ST3 — frontend	Stateless	C3 (uniforme)	Ponto de entrada único. O C3 isola se o gargalo é a receção HTTP ou as dependências internas. Contribui para a análise de custo marginal.

3 Decisão Arquitetural em Estudo

A decisão arquitetural central deste estudo é a **estratégia de escalamento horizontal**: escalar *seletivamente* apenas o(s) serviço(s) candidatos a *bottleneck* (C2), por oposição a escalar *uniformemente* todos os serviços *stateless* (C3). Esta decisão é avaliada experimentalmente nos cenários descritos na Secção 5.

A motivação para estudar esta decisão decorre de uma tensão arquitetural real: o escalamento seletivo é aparentemente mais eficiente (menos réplicas, menor custo), mas exige identificação prévia do bottleneck; o escalamento uniforme é operacionalmente mais simples mas ignora diferenças de carga entre serviços. A escolha entre estas estratégias tem impacto direto nos quatro atributos de qualidade em avaliação — **Performance, Availability, Deployability e Cost**.

Um fator arquitetural crítico condiciona ambas as estratégias: a *connection affinity* do gRPC/HTTP2 [8, 9]. O gRPC usa conexões persistentes e multiplexadas — uma vez estabelecida uma conexão a uma réplica, todos os pedidos nessa conexão continuam a ir para a mesma réplica. Novas réplicas só recebem tráfego quando novas conexões são abertas. Este comportamento, documentado na literatura técnica sobre balanceamento gRPC em Kubernetes [9], limita estruturalmente a eficácia do escalamento horizontal simples (`kubect1 scale`) em sistemas gRPC, independentemente da estratégia adotada.

3.1 Alternativas Consideradas

Auto-scaling horizontal (HPA por CPU/memória). O Kubernetes *Horizontal Pod Autoscaler* [6] ajusta o número de réplicas automaticamente com base em métricas. Melhora a **Performance** ao reagir à carga real; melhora a **Availability** sob carga variável; aumenta a complexidade de **Deployability** (requer configuração de métricas, limiares e políticas de *cooldown*); o **Cost** é variável — potencialmente menor em períodos calmos, mas com risco de *over-provisioning* em rajadas.

Caching no productcatalogservice. Introduzir uma cache em memória ou via Redis eliminaria o fan-out de 6 chamadas por browse, reduzindo drasticamente a pressão no serviço. Melhoria substancial de **Performance** sem adição de réplicas; **Availability** pode ser afetada por inconsistências de TTL; exige alteração de código (**Deployability** média); **Cost** potencialmente muito inferior ao escalamento (sem réplicas extras).

Service mesh com balanceamento por pedido (Istio/Linkerd). Um *service mesh* [7] introduz um proxy *sidecar* (ex: Envoy) em cada pod, funcionando como middleware acima do Kubernetes ao nível L7. Este middleware intercepta todo o tráfego gRPC e substitui o balanceamento por conexão por balanceamento por pedido (*round-robin* ou *least-connections*), resolvendo estruturalmente a *connection affinity* identificada em H6 [9]. Impacto nos atributos de qualidade: melhoria substancial de **Performance** ao distribuir carga uniformemente — as réplicas novas passariam a receber tráfego imediatamente, sem aguardar novas conexões; melhoria de **Availability** com *circuit breaking*, *retry* automático e detecção de réplicas degradadas; aumento significativo de complexidade operacional (**Deployability**) — o service mesh adiciona um componente de infraestrutura com a sua própria curva de aprendizagem, configuração e potencial de falha; overhead de CPU/memória do sidecar (~20–50 m por pod) impacta o **Cost**. Esta é a alternativa não implementada com maior potencial para resolver o problema central identificado neste estudo.

Escalamento vertical (ajuste de limites de recursos). Aumentar CPU/RAM dos pods existentes em vez de adicionar réplicas. Simplicidade máxima de **Deployability**; **Performance** limitada pelo teto do nó; **Availability** sem melhoria (sem redundância); **Cost** proporcional aos recursos alocados.

3.2 Trade-offs: Escalamento Seletivo vs. Uniforme

Tabela 3. Trade-offs da decisão central (C2 vs. C3) por atributo de qualidade.

Atributo	Seletivo (C2)	Uniforme (C3)
Performance	Ganho na latência mediana (−22% p50). Risco: se o bottleneck não for o serviço escalado, pode degradar (C2 < C1 nos exaustivos)	Maior ponto de saturação (150u vs 75u). Sem melhoria na mediana.
Availability	Serviços não escalados permanecem pontos únicos de falha	Redundância em todos os stateless; redis-cart é o único ponto único
Deployability	Requer identificação prévia do bottleneck (tracing, análise de CPU)	Mecânico, sem análise prévia; mais réplicas = mais complexidade de gestão
Cost	Menor custo absoluto (+2 réplicas); custo marginal negativo se mal direcionado	Custo 3× superior (+20 réplicas); ganho no ponto de saturação justifica parcialmente

A evidência experimental mostra que o escalamento seletivo (C2) é a decisão de maior risco: quando o serviço identificado como candidato a *bottleneck* não é o *bottleneck* real sob carga severa, as réplicas adicionais consomem recursos sem receber tráfego (efeito da *connection affinity* gRPC), degradando o sistema. O escalamento uniforme (C3) é mais robusto mas com custo marginal crescente.

4 Hipóteses

Tabela 4. Hipóteses formuladas, cenários de teste e estado após experimentação.

H	Hipótese	Cenário	Estado
H1	Escalar seletivamente melhora parcialmente, mas pode não deslocar o ponto de quebra se outro bottleneck dominar	C1 vs C2	✓ Confirmada
H2	Após aliviar o productcatalog, o redis-cart emerge como limitação em W2/W3	C2 obs.	○ Inconclusiva
H3	Ganho por réplica diminui com o deslocamento do bottleneck	C1→C2→C3	✓ Confirmada
H4	Custo marginal cresce quando réplicas deixam de produzir ganhos proporcionais	C2 vs C3	✓ Confirmada
H5	Escalamento horizontal é mais eficaz em stateless do que com dependência stateful	C2/C3 vs redis	○ Inconclusiva
H6	Connection affinity gRPC/HTTP2 limita a eficácia do escalamento horizontal	C2 CPU/-réplica	✓ Confirmada

5 Metodologia Experimental

5.1 Ambiente

Os testes foram executados num MacBook Air M4 (2026): Apple M4 10 cores (4P+6E), 16 GB RAM. O Kubernetes foi gerido pelo Docker Desktop, com o nó único a receber todos os 10 cores e ~7,6 GB de RAM. O ambiente local impõe limitações face a um cluster de produção (sem isolamento NUMA, variabilidade de processos do SO), devidamente consideradas na análise.

Foram necessários dois ajustes para Apple Silicon ARM64: aumento do *memory limit* do *cartservice* de 128 MiB para 512 MiB (evitar OOMKill sob carga) e a variável de ambiente *DOTNET_EnableWriteXorExecute* (corrigir *crash* do JIT .NET em ARM64). Todos os *deployments* usam *imagePullPolicy: Never* — imagens construídas e *tagged* localmente.

5.2 Ferramenta de Carga — Locust

A carga foi gerada com Locust [5] (Python), ferramenta incluída no projeto original. Foram implementados dois *locustfiles* com perfis de utilizador distintos.

Locustfile comparativo (think times realistas): CasualUser 30%/5–15s, NormalUser 50%/2–6s, PowerUser 20%/0,5–2s. A 25 utilizadores gera ≈8 RPS — insuficiente para saturar o sistema.

Locustfile exaustivo (think times agressivos): CasualUser 20%/0,5–1s, NormalUser 50%/0,2–0,5s, PowerUser 30%/0,1–0,2s. A 25 utilizadores gera ≈72 RPS. Permite encontrar o ponto de saturação real.

A existência de dois perfis distintos reflete papéis complementares: o comparativo permite comparar C1, C2 e C3 em condições controladas e equivalentes, a carga sub-saturação; o exaustivo procura forçar a saturação para identificar o ponto de rutura real de cada cenário. As inferências sobre throughput máximo sustentável e custo por pedido provêm exclusivamente do segundo perfil.

Os resultados dos dois conjuntos de testes não são diretamente comparáveis entre si — locustfiles diferentes, objetivos diferentes.

Pesos das tarefas (ambos): *browse*×10 · *view-cart*×3 · *add-to-cart*×2 · *moeda*×2 · *homepage*×1 · *checkout*×1. O workload não representa um único workflow isolado, mas uma composição de operações sobre a aplicação cuja interpretação deve ser feita à luz de W1 (principal driver de fan-out sobre o *productcatalogservice*), W2 (workflow associado ao carrinho e ao backend stateful) e W3 (workflow transacional de maior complexidade e latência acumulada). O *checkout* usa *catch_response=True* para não contaminar as métricas com falhas provenientes do *add-to-cart*. O loadgenerator nativo foi pausado (`kubectl scale --replicas=0`) em todas as execuções.

5.3 Cenários Experimentais

Tabela 5. Descrição dos três cenários experimentais.

Cenário	Configuração	+Rép.	Objetivo
C1	1 réplica por serviço	0	Referência; ponto de saturação natural
C2	<i>productcatalog</i> : 3; restantes: 1	+2	Escalar candidato a bottleneck primário
C3	Todos <i>stateless</i> : 3; <i>redis-cart</i> : 1	+20	Escalar tudo; rendimentos marginais?

Parâmetros de execução: warm-up de 30 s (permite estabilização inicial do sistema antes da recolha); janela de medição de 120 s por nível (observar o sistema num período relativamente estável); spawn rate 2 utilizadores/s (evitar subida demasiado brusca da carga); cooldown 60 s entre níveis. O critério de quebra ($p99 > 2000$ ms OU falhas $> 5\%$) é um limiar operacional consistente para identificar degradação severa e tornar comparável o ponto de rutura entre cenários — não representa um Service Level Agreement real da aplicação.

Testes comparativos: cargas fixas 15, 20, 25 utilizadores; locustfile realista; cada execução independente com cluster em estado limpo. Este isolamento entre execuções permite comparação rigorosa entre cenários à mesma carga.

Testes exaustivos: carga crescente 25→50→75→100→125→150 utilizadores dentro da *mesma execução*; locustfile agressivo; execução até ao critério de quebra ser atingido. O *cooldown* de 60 s reduz a transição abrupta mas não elimina efeitos herdados do nível anterior (conexões gRPC aquecidas, JIT compilado). O ponto de saturação assim obtido deve ser interpretado como indicativo de tendência de degradação, não como equivalente a execuções independentes por nível de carga.

5.4 Contexto Histórico — C1 Exploratório

Antes dos testes comparativos foi executado um teste exploratório de C1 com um *locustfile* simplificado (1 perfil, `wait_time` entre(0,5,1)) com carga crescente progressiva, para identificar o ponto de saturação do sistema e calibrar os níveis de carga. **Estes resultados não são comparáveis com os testes comparativos** — locustfile diferente, metodologia diferente.

Tabela 6. C1 Exploratório (locustfile simplificado, carga crescente). Saturação a 30 utilizadores com 47,6% de falhas — motivou a escolha de 15/20/25 utilizadores para os testes comparativos.

Users	p50	p90	p99	Falhas%	RPS	Estado
5	25ms	36ms	130ms	0,0%	1,71	OK
10	21ms	36ms	77ms	0,0%	3,41	OK
15	22ms	35ms	120ms	0,0%	4,98	OK
20	26ms	120ms	410ms	0,0%	6,60	Aviso — p90 sobe 3×
25	21ms	65ms	420ms	0,0%	8,35	Aviso
30	13ms	210ms	910ms	47,6%	8,79	SATURAÇÃO

A degradação do p90 entre 15 e 20 utilizadores (36 ms → 120 ms, aumento de 3×) e a posterior saturação a 30 utilizadores (47,6% de falhas HTTP 422, maioritariamente no *checkout* em cascata a partir de falhas no *add-to-cart*) motivaram a escolha dos níveis 15, 20 e 25 utilizadores para os testes comparativos — abrangendo o intervalo de degradação progressiva até ao limite antes da quebra, sem atingir saturação completa.

5.5 Métricas Recolhidas

Throughput (RPS), latências p50/p90/p99 e taxa de falhas — exportados pelo Locust em CSV. CPU e RAM por pod a cada 10s durante os testes via `kubectl top`, guardados em `monitoring/pods_metrics.csv`. Traces distribuídos via Jaeger para análise de dependências e ordem das chamadas.

5.6 Definição Operacional de Custo Marginal

$$CM_{throughput} = \frac{\Delta RPS}{\Delta Réplicas} \quad C_{proxy} = \frac{1}{2} \cdot CPU_{time} + \frac{1}{2} \cdot RAM_{time}$$

onde $CPU_{time} = \overline{cpu_m}/1000 \times t_s$ (CPU-segundos por réplica) e $RAM_{time} = \overline{ram_{MiB}} \times t_s$ (MiB-segundos por réplica), somados sobre todas as réplicas do cenário. O custo por pedido com sucesso é $C_{proxy}/pedidos_{sucesso}$, permitindo comparar cenários com throughputs diferentes.

Nota sobre as métricas: $CM_{throughput}$ mede o ganho de *throughput* por réplica adicional — é um indicador de eficiência de escalamento, não de custo diretamente. O custo marginal é capturado pelo C_{proxy} e pelo custo por pedido. Os pesos $\alpha = \beta = 0,5$ são uma escolha metodológica simplificadora para construir um indicador comparável entre cenários — as duas grandezas (CPU-s e MiB-s) têm unidades distintas e a sua soma não tem significado físico direto fora deste contexto comparativo. O C_{proxy} é um índice relativo, não uma grandeza monetária ou física absoluta.

Os valores de CPU e RAM foram obtidos a partir dos ficheiros `pods_after.txt` (medição pontual `kubectl top` no final de cada nível de carga), usando a média das três medições (15/20/25 utilizadores) $\times$ 120 s de janela de medição por nível. A Tabela 7 apresenta os resultados calculados.

Tabela 7. Custo proxy calculado para C1, C2 e C3 (testes comparativos, 15/20/25 utilizadores, $t_{total} = 360$ s). Unidades: CPU_time em CPU-s; RAM_time em MiB-s; $C_{proxy} = 0,5 \times CPU_time + 0,5 \times RAM_time$; custo/pedido em unidades proxy por pedido com sucesso.

Cenário	+Rép.	CPU_time	RAM_time	C_proxy	Req OK	Custo/req	Δ Custo/req	CM_{tp}
C1 — Baseline	0	59,8	353 640	176 850	2285	77,4	— (ref.)	—
C2 — Seletivo	+2	86,3	370 560	185 323	2301	80,5	+4%	−0,02
C3 — Uniforme	+20	84,2	817 320	408 702	2300	177,7	+130%	−0,003

Leitura: o C2 adicionou 2 réplicas e aumentou o custo por pedido apenas 4% — mas sem qualquer ganho de *throughput* ($CM_{tp} = -0,02$ RPS/réplica). O C3 adicionou 20 réplicas (+182% de pods) e o custo por pedido subiu 130% — com *throughput* marginalmente inferior ao C1 ($CM_{tp} = -0,003$ RPS/réplica). O RAM_time domina o custo proxy porque a RAM alocada é proporcional ao número de réplicas, enquanto a CPU real consumida é condicionada pela *connection affinity* (réplicas ociosas consomem pouca CPU mas continuam a ocupar RAM).

6 Resultados — Testes Comparativos

Os testes comparativos usaram o `locustfile` realista a 15, 20 e 25 utilizadores. A carga de 25 utilizadores não saturou nenhum dos três cenários. A Tabela 8 apresenta os resultados agregados; a Tabela 9 detalha a distribuição de CPU por réplica.

Como se observa na Tabela 8, os resultados revelam três padrões consistentes.

Throughput: praticamente idêntico nos 3 cenários ($\approx 7,9$ – $8,0$ RPS a 25 utilizadores). O escalamento não produz ganho de *throughput* porque o sistema não está saturado — resultado consistente com H3 e H4 nesta gama de carga.

Latência mediana (p50): o C2 apresenta a melhor mediana (14 ms a 25u, −22% face ao C1). Este ganho é compatível com uma distribuição parcial de carga no `productcatalogservice` quando novas conexões são abertas.

Latência cauda (p99): o C1 tem os melhores p99. O C2 e C3 mostram picos mais altos (290 ms e 110 ms vs. 69 ms no C1 a 25u) — padrão consistente com réplicas novas menos “aquecidas” (JIT não otimizado, caches frias) e com a hipótese de H6.

Como se observa na Tabela 9, a distribuição de CPU no C2 revela: `productcatalogservice` #1: 31m | #2: 2m | #3: 1m — distribuição de 91%/6%/3%. As duas réplicas novas ficaram praticamente inativas porque as conexões HTTP/2 existentes permaneceram na réplica original — observação fortemente sugerida pela hipótese H6 (*connection affinity* gRPC/HTTP2).

Tabela 8. Resultados comparativos C1, C2 e C3 (testes com locustfile realista). A carga de 25 utilizadores não satura nenhum cenário — o throughput é praticamente idêntico (≈ 8 RPS).

Users	p50	p90	p99	Falhas%	RPS
<i>C1 — Baseline (1 réplica por serviço)</i>					
15	20ms	30ms	62ms	0,0%	4,80
20	18ms	31ms	52ms	0,0%	6,36
25	18ms	31ms	69ms	0,0%	7,98
<i>C2 — Seletivo (productcatalogservice $\times 3$)</i>					
15	16ms	27ms	170ms	0,0%	4,92
20	16ms	25ms	86ms	0,0%	6,42
25	14ms	25ms	290ms	0,0%	7,94
<i>C3 — Uniforme (todos stateless $\times 3$; redis-cart $\times 1$)</i>					
15	21ms	38ms	200ms	0,0%	4,78
20	19ms	32ms	96ms	0,0%	6,57
25	19ms	31ms	110ms	0,0%	7,92

Tabela 9. Distribuição de CPU por serviço e por réplica nos três cenários a 25 utilizadores (valores kubectl top, em millicores). Evidencia a *connection affinity* gRPC (H6): réplicas novas ficam subutilizadas enquanto a original acumula carga.

Serviço	C1 — 1 réplica	C2 — productcatalog $\times 3$	C3 — todos stateless $\times 3$
frontend	50m	70m (1 réplica)	$\sim 16m + 17m + 16m$ (bem distribuído)
currencyservice	47m	55m (1 réplica)	$\sim 26m + 17m + 2m$ (desigual)
recommendationservice	31m	47m (1 réplica)	$\sim 39m$ distribuídos (3 réplicas)
productcatalogservice	21m	#1: 31m #2: 2m #3: 1m	$\sim 14m + 7m + 3m$ (desigual)
cartservice	23m	23m (1 réplica)	$\sim 29m$ distribuídos (3 réplicas)
redis-cart (stateful)	4m	5m (sem alteração)	4m (sem alteração)

O frontend é o único serviço que distribui bem a carga em C3 ($\sim 16m+17m+16m$), porque recebe conexões HTTP/1.1 externas — sem persistência HTTP/2, cada pedido pode ser roteado independentemente. Todos os outros serviços exibem distribuição desigual entre réplicas, resultado consistente com a *connection affinity* como fenómeno estrutural do gRPC/HTTP2 e não específico de um serviço em particular.

7 Resultados — Testes Exaustivos

Os testes exaustivos usaram o locustfile agressivo para encontrar o ponto de saturação real de cada cenário.

Tabela 10. Resultados exaustivos C1 (1 réplica). Quebra a 75 utilizadores com 23,5% de falhas.

Users	p50	p90	p99	Falhas%	RPS	Estado
25	47ms	130ms	660ms	0,0%	71,8	Aviso
50	160ms	280ms	1500ms	0,0%	88,1	Aviso
75	330ms	520ms	1800ms	23,5%	100,4	QUEBRA




Fig. 1. Distribuição de CPU entre as 3 réplicas do productcatalogservice em C2 a 25u. A réplica original absorve 97,9% do tráfego — evidência empírica da *connection affinity* gRPC/HTTP2 (H6).

Tabela 11. Resultados exaustivos C2 (productcatalogservice ×3). Quebra a 50 utilizadores — *pior* que o C1.

Users	p50	p90	p99	Falhas%	RPS	Estado
25	50ms	140ms	460ms	0,0%	71,0	Aviso
50	160ms	390ms	3700ms	27,9%	76,1	QUEBRA

Tabela 12. Resultados exaustivos C3 (todos stateless ×3). Saturação entre 125 e 150 utilizadores.

Users	p50	p90	p99	Falhas%	RPS	Estado
25	20ms	110ms	720ms	0,0%	74,9	Aviso
50	140ms	370ms	560ms	0,0%	99,4	Aviso
75	210ms	700ms	1100ms	0,1%	103,1	Aviso
100	240ms	710ms	1000ms	0,0%	124,2	Aviso
125	310ms	970ms	1300ms	0,5%	123,4	Aviso
150 (incremental)	350ms	1200ms	1500ms	0,0%	130,5	Aviso
150 (arranque a frio)	340ms	1500ms	2500ms	0,0%	109,1	QUEBRA

O resultado do C4 é contra-intuitivo: escalar os bottlenecks *identificados* (frontend e currencyservice) produziu o pior resultado de todos. A análise de CPU após medição revela o mecanismo: o cartservice (1 réplica) atingiu 115m de CPU — o valor mais alto de qualquer serviço em qualquer cenário. Com 3 réplicas de frontend a abrir conexões gRPC independentes ao cartservice, a




Fig. 2. CPU total por serviço (millicores) no ponto de saturação de cada cenário. C3 mostra total das 3 réplicas por serviço; C4 revela o cartservice como novo bottleneck (115 m).

Tabela 13. Resultados exaustivos C4 (frontend ×3 + currencyservice ×3). Quebra imediata a 25 utilizadores com 77,1% de falhas — pior de todos os cenários.

Users	p50	p90	p99	Falhas%	RPS	Estado
25	6ms	120ms	2300ms	77,1%	66,8	QUEBRA

pressão de conexões neste serviço triplicou, criando um novo bottleneck nos backends não escalados. Adicionalmente, a *connection affinity* continuou a atuar no currencyservice (distribuição 45m/55m/3m), mantendo uma réplica quase inativa. O C4 confirma que escalar um subconjunto de serviços, mesmo os mais pressionados, desloca o bottleneck para as dependências não escaladas.

Tabela 14. Comparação dos pontos de saturação entre todos os cenários (testes exaustivos). C4 adicionado como cenário exploratório.

Cenário	+Rép.	Quebra	RPS máx.	Falhas%	Conclusão
C1 — Baseline	0	75u	100,4	23,5	Referência
C2 — Seletivo (productcatalog ×3)	+2	50u	76,1	27,9	Pior que C1
C4 — Seletivo (frontend+currency ×3)	+4	25u	66,8	77,1	Pior de todos
C3 — Uniforme (todos stateless ×3)	+20	~150u	130,5	0,0	~2× mais que C1

Nota metodológica (carga incremental vs. arranque a frio): no C3, o teste com carga incremental (25→150u) chegou a 150u sem quebrar (p99=1500ms), mantendo conexões gRPC




Fig. 3. Throughput (RPS) vs. carga por cenário (testes exaustivos). C3 é o único cenário a crescer até 150u; C4 quebra imediatamente a 25u. Marcadores × indicam ponto de quebra.

aquecidas e JIT compilado. O teste de arranque a frio direto a 150u quebrou (p99=2500ms). O arranque a frio é a medida mais honesta do ponto de saturação real — a carga incremental subestima a latência por efeito de aquecimento progressivo.

7.1 Custo Proxy — Testes Exaustivos

Os testes comparativos mostraram throughputs idênticos nos três cenários — impossibilitando uma comparação de custo significativa. Os testes exaustivos, ao atingirem os pontos de saturação reais de cada cenário, permitem calcular um custo proxy mais informativo: o custo por pedido no regime em que cada configuração está a ser efetivamente exigida.

O custo proxy foi calculado com a mesma fórmula ($C_{proxy} = 0,5 \times CPU_{time} + 0,5 \times RAM_{time}$), usando medições pontuais `kubectl top` por nível de carga de cada cenário. Para o C1 acumulam-se os três níveis antes da quebra (25/50/75u); para o C2 os dois níveis antes da quebra (25/50u); para o C3 apenas o nível de saturação (150u, arranque a frio); para o C4 apenas o único nível executado (25u, quebra imediata).

Como se observa na Tabela 15, os dados revelam quatro padrões com implicações arquiteturais distintas:

C2 — custo marginal negativo por ineficácia gRPC. As 2 réplicas adicionais aumentaram o custo por pedido em 30% e o $CM_{tp} = -12,15$ RPS/réplica significa que cada réplica adicional *reduziu* a capacidade do sistema em 12 RPS. A *connection affinity* fez com que as réplicas extras consumissem RAM/CPU sem receber tráfego, degradando os bottlenecks reais.

C4 — custo por pedido 6× superior ao C2, 40 vezes superior ao C1. As 4 réplicas adicionais (frontend ×3 + currencyservice ×3) produziram 77,1% de falhas a 25u — apenas 1.835 pedidos com sucesso em toda a execução. O custo proxy de 38,96 unidades/pedido é o mais elevado de todos




Fig. 4. Latência p99 (ms) vs. carga por cenário (escala logarítmica). A linha a tracejado vermelho indica o critério de quebra (2000 ms). C2 excede o critério a 50u; C4 excede a 25u.




Fig. 5. Ponto de saturação (utilizadores até quebra) por cenário. C2 quebra *antes* do C1; C4 é o pior de todos. Linha de referência a tracejado: C1 a 75u.

os cenários porque o numerador (custo total) é semelhante ao C2 mas o denominador (pedidos bem-sucedidos) colapsa para menos de 2.000. O C4 ilustra o efeito cascata: escalar os serviços

Tabela 15. Custo proxy nos testes exaustivos por cenário, ao ponto de saturação. C_{proxy} em unidades proxy; custo/pedido = C_{proxy} / pedidos com sucesso; CM_{tp} = ganho de RPS por réplica adicional face ao C1. C4 incluído como cenário exploratório. Legenda: “incr.” = carga incremental; “a.f.” = arranque a frio.

Cenário	Pods	C_{proxy}	Req OK	Custo/req	Δ Custo	CM_{tp}
C1 – Baseline	11	184 099	28 241	6,52	—	—
C2 – Seletivo (productcatalog)	13	127 303	15 031	8,47	+30%	−12,15 RPS/rép.
C4 – Seletivo (frontend+cur.)	15	71 487	1 835	38,96	+498%	−8,40 RPS/rép.
C3 – Uniforme (todos stateless)	30	141 659	13 034	10,87	+67%	+0,44 RPS/rép.

de entrada multiplica a carga de conexões gRPC nos backends não escalados, criando um novo bottleneck mais destrutivo que o original.

C3 – rendimentos marginais ínfimos mas positivos. As 20 réplicas adicionais aumentaram o custo por pedido em 67% mas o CM_{tp} = +0,44 RPS/réplica é o único valor positivo de todos os cenários seletivos.

RAM_time domina em todos os cenários. Réplicas inativas continuam a ocupar memória independentemente da carga recebida. Num ambiente de nó único, esta pressão de RAM é o mecanismo principal que limita a escalabilidade horizontal sem balanceamento ao nível de pedido.




Fig. 6. Custo proxy por pedido (índice relativo) nos testes comparativos e exaustivos. C4 destaca-se com custo 498% acima do C1 nos exaustivos, consequência de 77,1% de falhas a colapsar o denominador.

7.2 Rendimentos Marginais por Nível de Carga

A análise anterior calcula o CM_{tp} de cada cenário ao respectivo ponto de saturação. Uma perspectiva complementar compara C1 e C3 ao *mesmo* nível de carga, mostrando como o benefício marginal das réplicas adicionais evolui com a intensidade da carga.

*C1 quebrou a 75u com 23,5% de falhas.

A Tabela 16 revela que o CM_{tp} não é constante — é máximo quando o C1 está perto da saturação (50u: +0,565 RPS/réplica) e colapsa quando ambos os sistemas se aproximam dos seus limites (75u:

Tabela 16. Rendimento marginal do C3 face ao C1 por nível de carga (testes exaustivos, +20 réplicas). $CM_{tp} = \Delta RPS / 20$ réplicas. Custo/req calculado com C_{proxy} real a cada nível.

Nível	C1 RPS	C3 RPS	ΔRPS	CM_{tp}	C1 custo/req	C3 custo/req
25u	71,8	74,9	+3,1	+0,155 RPS/rép.	7,08	14,76 (+108%)
50u	88,1	99,4	+11,3	+0,565 RPS/rép.	5,82	11,49 (+98%)
75u	100,4*	103,1	+2,7	+0,135 RPS/rép.	6,68*	11,26 (+69%)

+0,135 RPS/réplica). A 25u, com o sistema ainda confortavelmente abaixo da saturação, o ganho é mínimo (+0,155 RPS/réplica). O custo por pedido do C3 é sistematicamente $\approx 2\times$ o do C1 ao mesmo nível de carga, independentemente da intensidade — confirmando que o custo das réplicas adicionais é fixo enquanto o ganho de throughput é variável e dependente do estado de saturação do sistema.

7.3 Lei de Amdahl e o Tecto Teórico do Escalamento

A Lei de Amdahl [10] fornece um enquadramento teórico para os rendimentos marginais decrescentes observados. Dado que uma fracção s do trabalho é serial (não beneficia de paralelismo) e N é o número de réplicas por serviço, o speedup máximo é:

$$S(N, s) = \frac{1}{s + \frac{1-s}{N}} \quad (1)$$

O speedup real observado no C3 é $S_{real} = 130,5/100,4 \approx 1,30\times$ com $N = 3$ réplicas por serviço. Invertendo a equação 1 para determinar a fracção serial efectiva:

$$s = \frac{N/S - 1}{N - 1} = \frac{3/1,30 - 1}{3 - 1} = \frac{1,308}{2} \approx 0,654 \quad (2)$$

Apesar de todos os serviços stateless terem sido escalados para 3 réplicas, **65,4% do trabalho comporta-se como serial** — como se não pudesse ser paralelizado. A causa estrutural é a *connection affinity* do gRPC/HTTP2: as conexões existentes permanecem nas réplicas originais, tornando as novas réplicas praticamente inactivas. Do ponto de vista de Amdahl, isto é equivalente a converter trabalho potencialmente paralelo em serial.

Tabela 17. Speedup teórico (Lei de Amdahl) vs real, com $s = 0,654$ (fracção serial efectiva determinada experimentalmente). Limite teórico: $1/s \approx 1,53\times$.

N réplicas	Ideal ($s = 0$)	Com $s = 0,654$	Real (observado)
3	3,00×	1,30×	1,30× ✓
5	5,00×	1,38×	—
10	10,00×	1,45×	—
20	20,00×	1,49×	— (limite $\approx 1,53\times$)

A Tabela 17 mostra que, com $s = 0,654$, adicionar réplicas além de $N = 3$ produz retorno marginal ínfimo: passar de 3 para 20 réplicas por serviço aumentaria o speedup apenas de $1,30\times$ para $1,49\times$ — um ganho de $0,19\times$ para $17\times$ mais réplicas. O limite teórico absoluto é $1/s \approx 1,53\times$, independentemente do número de réplicas. Esta análise fornece uma justificação teórica para os rendimentos marginais decrescentes observados em H3 e H4, e quantifica o custo arquitectural

da *connection affinity*: sem balanceamento ao nível de pedido, o sistema tem efectivamente uma fracção serial de 65%, reduzindo o tecto de Amdahl de ∞ para $\approx 1,53\times$.

8 Discussão

8.1 Resposta às Questões de Investigação

RQ1 — Que serviços dominam a degradação? Nas condições testadas (ambiente local, Docker Desktop, perfil de carga exaustivo), os serviços mais pressionados são o frontend e o *currencyservice*, não o *productcatalogservice*. O *productcatalogservice* é muito chamado ($\times 6$ por browse) mas é rápido; os seus chamadores acumulam CPU porque processam cada pedido HTTP de entrada. Esta observação, consistente com a hipótese H6, tem implicações diretas para a estratégia de escalamento, mas não deve ser generalizada como verdade absoluta sobre a aplicação — em configurações ou cargas distintas, a distribuição de pressão pode ser diferente.

RQ2 — Escalar o mais pressionado melhora? Não, e o cenário C4 é a demonstração mais clara. Identificados os bottlenecks reais (frontend e *currencyservice*) através dos testes exaustivos C1, desenhou-se o C4 para os escalar directamente. O resultado: quebra a 25u com 77,1% de falhas — pior de todos os cenários. O escalamento do frontend (ponto de entrada HTTP/1.1) triplicou a pressão de conexões gRPC nos backends não escalados (o *cartservice* atingiu 115m de CPU, o valor mais alto observado em qualquer serviço em qualquer cenário). O C2, por sua vez, tinha falhado por não escalar os bottlenecks correctos; o C4 falhou por escalar os bottlenecks correctos sem escalar as suas dependências. H1 é confirmada: em ambos os casos, o escalamento seletivo degradou o sistema sob carga severa.

RQ3 — O ganho justifica o custo? Nas condições testadas, não, em nenhum dos cenários seletivos. O C2 apresenta $CM_{tp} = -12,15$ RPS/réplica e o C4 apresenta $CM_{tp} = -8,40$ RPS/réplica — ambos com ganho marginal de throughput negativo. O C4 tem ainda o custo por pedido mais elevado (38,96 unidades/pedido, 498% acima do C1) porque o denominador colapsa com 77,1% de falhas. O C3 (+20 réplicas) é o único com CM_{tp} positivo (+0,44 RPS/réplica), mas com custo por pedido 67% superior ao C1. Os resultados são consistentes com as hipóteses H3 e H4 (rendimentos marginais decrescentes); o custo marginal negativo nos cenários seletivos é a evidência mais forte desta tendência.

RQ4 — Serviços stateless vs. stateful? O *redis-cart* manteve-se a 4–14m CPU mesmo a 150u — sem sinais de saturação nas cargas testadas. A hipótese de que o componente stateful limitaria o escalamento (H2, H5) não encontrou evidência experimental direta. Seriam necessárias cargas superiores para observar este efeito.

8.2 Porque é que o Throughput não Melhorou nos Testes Comparativos

Os três cenários produziram throughputs praticamente idênticos ($\approx 7,9$ – $8,0$ RPS a 25 utilizadores). Duas explicações complementares:

1. Sistema não saturado. O C1 exploratório confirmou que o ponto de quebra está a 30 utilizadores. Se o sistema não está saturado, adicionar réplicas não pode melhorar o throughput — não existe fila de espera para distribuir. O escalamento só produz ganho de throughput quando o bottleneck está efetivamente saturado.

2. Connection affinity limita o scale-out. Mesmo quando a carga seria suficiente para saturar, as réplicas novas não recebem tráfego das conexões HTTP/2 já estabelecidas. A distribuição 91%/6%/3% no *productcatalogservice* do C2 confirma este efeito. A implicação é arquiteturalmente importante: em sistemas gRPC/HTTP2, *kubect1 scale* pode não produzir os ganhos esperados sem balanceamento ao nível de pedido.

8.3 Dicotomia p50/p99: Porque Melhorou a Mediana mas Piorou a Cauda

O C2 melhorou o p50 (-22%) mas piorou o p99 (+320%). Este aparente paradoxo tem explicação direta na *connection affinity*:

O **p50 melhorou** porque, quando novas conexões são abertas (ex: reinício do Locust, novos utilizadores), os pedidos podem ser roteados para réplicas menos carregadas — reduzindo a latência mediana ao evitar concorrência momentânea na réplica original.

O **p99 piorou** porque representa os 1% de pedidos mais lentos — que incluem precisamente os casos em que conexões são roteadas para réplicas novas, menos “aquecidas” (JIT não otimizado, caches frias, inicialização de *goroutines*). Cada nova réplica tem um período de arranque com latência mais alta; com mais réplicas, há mais momentos de latência elevada, aumentando o p99.

Esta dicotomia p50/p99 é uma característica estrutural dos sistemas com *connection affinity*: **ganho na mediana, perda na cauda**. Para melhorar simultaneamente ambas as métricas seria necessário balanceamento ao nível de pedido — que garante que réplicas novas recebem carga progressiva e aquecida em vez de rajadas imprevisíveis.

8.4 Efeito Cascata no C4: Escalar os Bottlenecks Certos não Chega

O C4 foi desenhado como teste de controlo: se o C2 falhou por escalar o serviço errado, escalar os serviços certos (frontend e *currency*service, identificados como bottlenecks reais nos exaustivos C1) deveria produzir melhorias. O resultado foi o oposto — quebra a 25u com 77,1% de falhas, antes de qualquer outro cenário.

O mecanismo é distinto do C2. O frontend recebe pedidos HTTP/1.1 de clientes externos; o Kubernetes Service distribui estes pedidos ao nível L4 entre as 3 réplicas, o que funciona razoavelmente (distribuição 50m/58m/35m de CPU — muito mais uniforme do que os serviços gRPC internos). O problema está nos backends: cada réplica de frontend abre o seu próprio conjunto de conexões gRPC a todos os serviços downstream. Com 3 réplicas de frontend, o *cart*service (1 réplica) passa a receber conexões de 3 clientes em vez de 1. O resultado: *cart*service a 115m de CPU, tornando-se o novo bottleneck.

Este efeito cascata ilustra uma propriedade estrutural das arquitecturas de microserviços com gRPC: **escalar qualquer serviço intermediário multiplica a carga de conexões nos seus dependentes**. Sem escalar a cadeia completa de dependências, o bottleneck apenas se desloca — não desaparece. O C3, ao escalar todos os serviços stateless uniformemente, é o único cenário que evita este efeito.

8.5 O Resultado Mais Surpreendente: C2 < C1

O resultado mais significativo deste estudo é o facto de o C2 (escalamento seletivo com +2 réplicas) ter atingido saturação antes do C1 (baseline sem escalamento). Este resultado, aparentemente paradoxal, é explicado por dois mecanismos que se reforçam mutuamente:

- (1) **Connection affinity do gRPC/HTTP2:** as réplicas novas do *productcatalogservice* receberam 2m e 1m de CPU (vs. 31m da réplica original) — distribuição de 91%/6%/3%. As conexões HTTP/2 existentes do frontend e *recommendationservice* permaneceram na réplica original; as novas réplicas só recebem tráfego quando novas conexões são abertas.
- (2) **Consumo de recursos sem retorno:** as duas réplicas adicionais, apesar de praticamente inativas do ponto de vista de tráfego, consomem RAM e CPU do nó Kubernetes. Num ambiente com recursos finitos (nó único com ~7,6 GB de RAM), esta pressão extra deixa menos recursos disponíveis para os bottlenecks reais (frontend, *currency*service), acelerando a saturação.

Este resultado é a evidência experimental mais forte em suporte da hipótese H6 e tem uma implicação arquitetural direta: em sistemas gRPC/HTTP2 [8], o escalamento horizontal simples (`kubectl scale`) pode ser não só ineficaz como prejudicial, sem um mecanismo de balanceamento ao nível de pedido (ex: service mesh com *load balancing* por pedido [9]).

8.6 Leitura pelos Atributos de Qualidade

Performance: o escalamento uniforme (C3) é o único cenário que melhora significativamente o ponto de saturação ($\sim 2\times$). O escalamento seletivo (C2) melhora a latência mediana a carga baixa mas degrada o sistema a carga severa.

Availability: o C3 distribui a redundância por todos os serviços *stateless*, eliminando pontos únicos de falha ao nível aplicacional. O `redis-cart` permanece como único ponto de falha em todos os cenários — limitação estrutural da arquitetura atual.

Deployability: o escalamento seletivo exige identificação prévia do bottleneck (tracing, análise de CPU por réplica), o que requer instrumentação e capacidade de observabilidade. O escalamento uniforme é operacionalmente mais simples mas implica gestão de mais réplicas.

Cost: os dois cálculos de custo proxy (Tabelas 7 e 15) contam histórias complementares. Nos testes comparativos (sistema não saturado), nenhum cenário gerou retorno. Nos testes exaustivos, o C2 tem $CM_{tp} = -12,15$ RPS/réplica e o C4 tem $CM_{tp} = -8,40$ RPS/réplica — ambos com custo marginal negativo. O C4 é o caso extremo: custo por pedido de 38,96 unidades (498% acima do C1) porque a taxa de 77,1% de falhas colapsa o denominador de pedidos com sucesso. O único cenário com CM_{tp} positivo é o C3 (+0,44 RPS/réplica), mas com custo por pedido 67% superior ao C1. O `RAM_time` domina em todos os casos porque réplicas inativas ocupam memória sem processar pedidos. A conclusão é inequívoca: em sistemas gRPC sem balanceamento ao nível de pedido, o escalamento horizontal simples apresenta custo marginal crescente e tende a ser negativo nos cenários seletivos.

8.7 Limitações

Os testes foram executados num ambiente local de nó único (Docker Desktop), sem isolamento NUMA nem partilha de recursos com outros tenants. Em produção, os pods teriam limites de recursos por nó mais apertados, o que alteraria significativamente os pontos de saturação. Os resultados são válidos para a arquitetura e configuração testadas, mas não devem ser extrapolados diretamente para ambientes de produção multi-nó.

A repetição de experiências com análise estatística (médias, desvios-padrão por nível de carga) seria necessária para separar o sinal de ruído ambiental e validar a estabilidade dos pontos de saturação — este é um ponto de melhoria prioritário para trabalho futuro. Os testes exaustivos foram executados uma vez por nível de carga; a variabilidade observada (ex: `step-up` vs. `arranque a frio` no C3 a 150u: p99 de 1500 ms vs. 2500 ms) ilustra que a repetição teria impacto relevante nas conclusões. As comparações entre cenários devem ser lidas como indicativas de tendências, não como valores estáveis.

9 Conclusões

9.1 Resultados por Cenário

C1 — Baseline. O sistema com 1 réplica por serviço suporta até 75 utilizadores com o `locustfile` exaustivo (≈ 100 RPS), com degradação progressiva a partir de 50u (p99 a 1500 ms). Os serviços mais pressionados nas condições testadas são o `frontend` (199 m CPU), `recommendationservice` (200 m) e `currencyservice` (173 m). O `redis-cart` manteve-se abaixo de 15 m em todos os níveis — sem sinais de contenção *stateful* nas cargas testadas.

C2 — Escalamento seletivo (productcatalogservice ×3). Resultado contra-intuitivo: quebra a 50u, *antes* do baseline. As réplicas adicionais do productcatalogservice absorveram apenas 2% do tráfego (97,9% permaneceu na réplica original — Figura 1), mas consumiram RAM e CPU do nó, degradando os serviços realmente pressionados. Este resultado é consistente com H6 e representa a evidência empírica mais forte do estudo.

C3 — Escalamento uniforme (todos stateless ×3). O único cenário com CM_{tp} positivo (+0,44 RPS/réplica): saturação a ~150u, $\approx 2\times$ mais que o C1. O custo por pedido sobe 67% (exaustivos) e 130% (comparativos). A fração serial efetiva de 65% (Lei de Amdahl) mostra que o teto teórico é $\approx 1,53\times$ — próximo do observado (1,30 $\times$). Escalar além de 3 réplicas produziria ganhos marginais ínfimos.

C4 — Escalamento dos bottlenecks identificados (frontend ×3 + currencyservice ×3). O pior resultado: quebra a 25u com 77,1% de falhas. Escalar o frontend (ponto de entrada HTTP/1.1) triplicou as conexões gRPC nos backends não escalados: o cartservice atingiu 115 m de CPU (Figura 2), tornando-se o novo bottleneck. O C4 demonstra que identificar os serviços mais pressionados em métricas de CPU não é suficiente — é necessário escalar toda a cadeia de dependências.

9.2 Resposta às Questões de Investigação

RQ1 — Nas condições testadas, os serviços mais pressionados são o frontend e o currencyservice, não o productcatalogservice. O fan-out $\times 6$ cria volume mas não saturação; os serviços de entrada acumulam CPU por processarem cada pedido HTTP.

RQ2 — Não. C2 (−25u face ao C1) e C4 (−50u face ao C1) demonstram que escalar o(s) serviço(s) mais pressionado(s) degrada o sistema quando a *connection affinity* e os efeitos de cascata não são considerados.

RQ3 — O ganho não justifica o custo em nenhum cenário seletivo. C2: $CM_{tp} = -12,15$ RPS/réplica; C4: $CM_{tp} = -8,40$ RPS/réplica. C3 tem $CM_{tp} = +0,44$ RPS/réplica — positivo, mas com custo por pedido 67% superior ao C1.

RQ4 — O redis-cart não foi fator limitante nas cargas testadas (máx. 15 m CPU a 150u). H2 e H5 permanecem inconclusivas — cargas superiores seriam necessárias para observar a limitação stateful.

9.3 Leitura pelos Atributos de Qualidade

Performance: só o C3 melhora significativamente o ponto de saturação. O escalamento seletivo melhora a latência mediana a carga baixa (C2: −22% p50) mas degrada a carga severa.

Availability: o C3 elimina pontos únicos de falha ao nível aplicacional; o redis-cart permanece como único ponto de falha em todos os cenários.

Deployability: o escalamento seletivo exige identificação prévia do bottleneck (tracing, CPU por réplica); o uniforme é operacionalmente mais simples mas multiplica a complexidade de gestão.

Cost: C2 e C4 têm custo marginal negativo — adicionam réplicas sem retorno e comprometem o sistema. C3 tem custo por pedido sistematicamente $\approx 2\times$ o do C1 ao mesmo nível de carga.

9.4 Implicação Arquitetural Central

Em sistemas gRPC/HTTP2, o `kubect1 scale` simples é uma ferramenta de eficácia limitada e potencialmente prejudicial sem balanceamento ao nível de pedido. O service mesh (Istio/Linkerd) é a alternativa arquitetural que resolveria estruturalmente o problema identificado, ao operar como middleware L7 acima do Kubernetes — distribuindo pedidos, não conexões. Em arquiteturas com dependências em cadeia, o escalamento seletivo desloca o bottleneck; só o escalamento uniforme (ou o service mesh) o elimina.

9.5 Limitações e Trabalho Futuro

Os resultados foram obtidos num ambiente local de nó único, sem repetição de execuções. A variabilidade observada (step-up vs. arranque a frio no C3: p99 de 1500 vs. 2500 ms) sublinha a necessidade de repetição com análise estatística. Trabalho futuro prioritário: (1) repetição de C1/C2/C3 três vezes por nível com média $\pm$ desvio-padrão; (2) implementação de HPA e service mesh para validar as alternativas discutidas; (3) carga progressiva até à saturação do redis-cart (H2/H5 inconclusivas).

Referências

- [1] Google Cloud. *Online Boutique: Cloud-native microservices demo application*. 2024. Disponível em: <https://github.com/GoogleCloudPlatform/microservices-demo>
- [2] Google. *gRPC: A high performance, open source universal RPC framework*. 2024. Disponível em: <https://grpc.io>
- [3] OpenTelemetry Authors. *OpenTelemetry: Observability framework for cloud-native software*. 2024. Disponível em: <https://opentelemetry.io>
- [4] Jaeger Authors. *Jaeger: Open source, end-to-end distributed tracing*. 2024. Disponível em: <https://www.jaegertracing.io>
- [5] Locust Authors. *Locust: An open source load testing tool*. 2024. Disponível em: <https://locust.io>
- [6] Kubernetes Authors. *Horizontal Pod Autoscaling*. 2024. Disponível em: <https://kubernetes.io/docs/tasks/run-application/horizontal-pod-autoscale/>
- [7] W. Morgan. *What's a service mesh? And why do I need one?* Buoyant, 2017.
- [8] gRPC Authors. *gRPC Load Balancing*. gRPC documentation, 2024. Disponível em: <https://grpc.io/blog/grpc-load-balancing/>
- [9] L. Liu e A. Strzoda. *gRPC Load Balancing on Kubernetes without Tears*. Kubernetes Blog, 2018. Disponível em: <https://kubernetes.io/blog/2018/11/07/grpc-load-balancing-on-kubernetes-without-tears/>
- [10] G. M. Amdahl. *Validity of the single processor approach to achieving large scale computing capabilities*. In Proceedings of AFIPS Spring Joint Computer Conference, pp. 483–485, 1967.
- [11] S. Newman. *Building Microservices: Designing Fine-Grained Systems*. 2ª ed. O'Reilly Media, 2021.
- [12] M. Fowler e J. Lewis. *Microservices*. martinowler.com, 2014. Disponível em: <https://martinfowler.com/articles/microservices.html>